FI-80NL169-4

中文版「言選Web」の評価

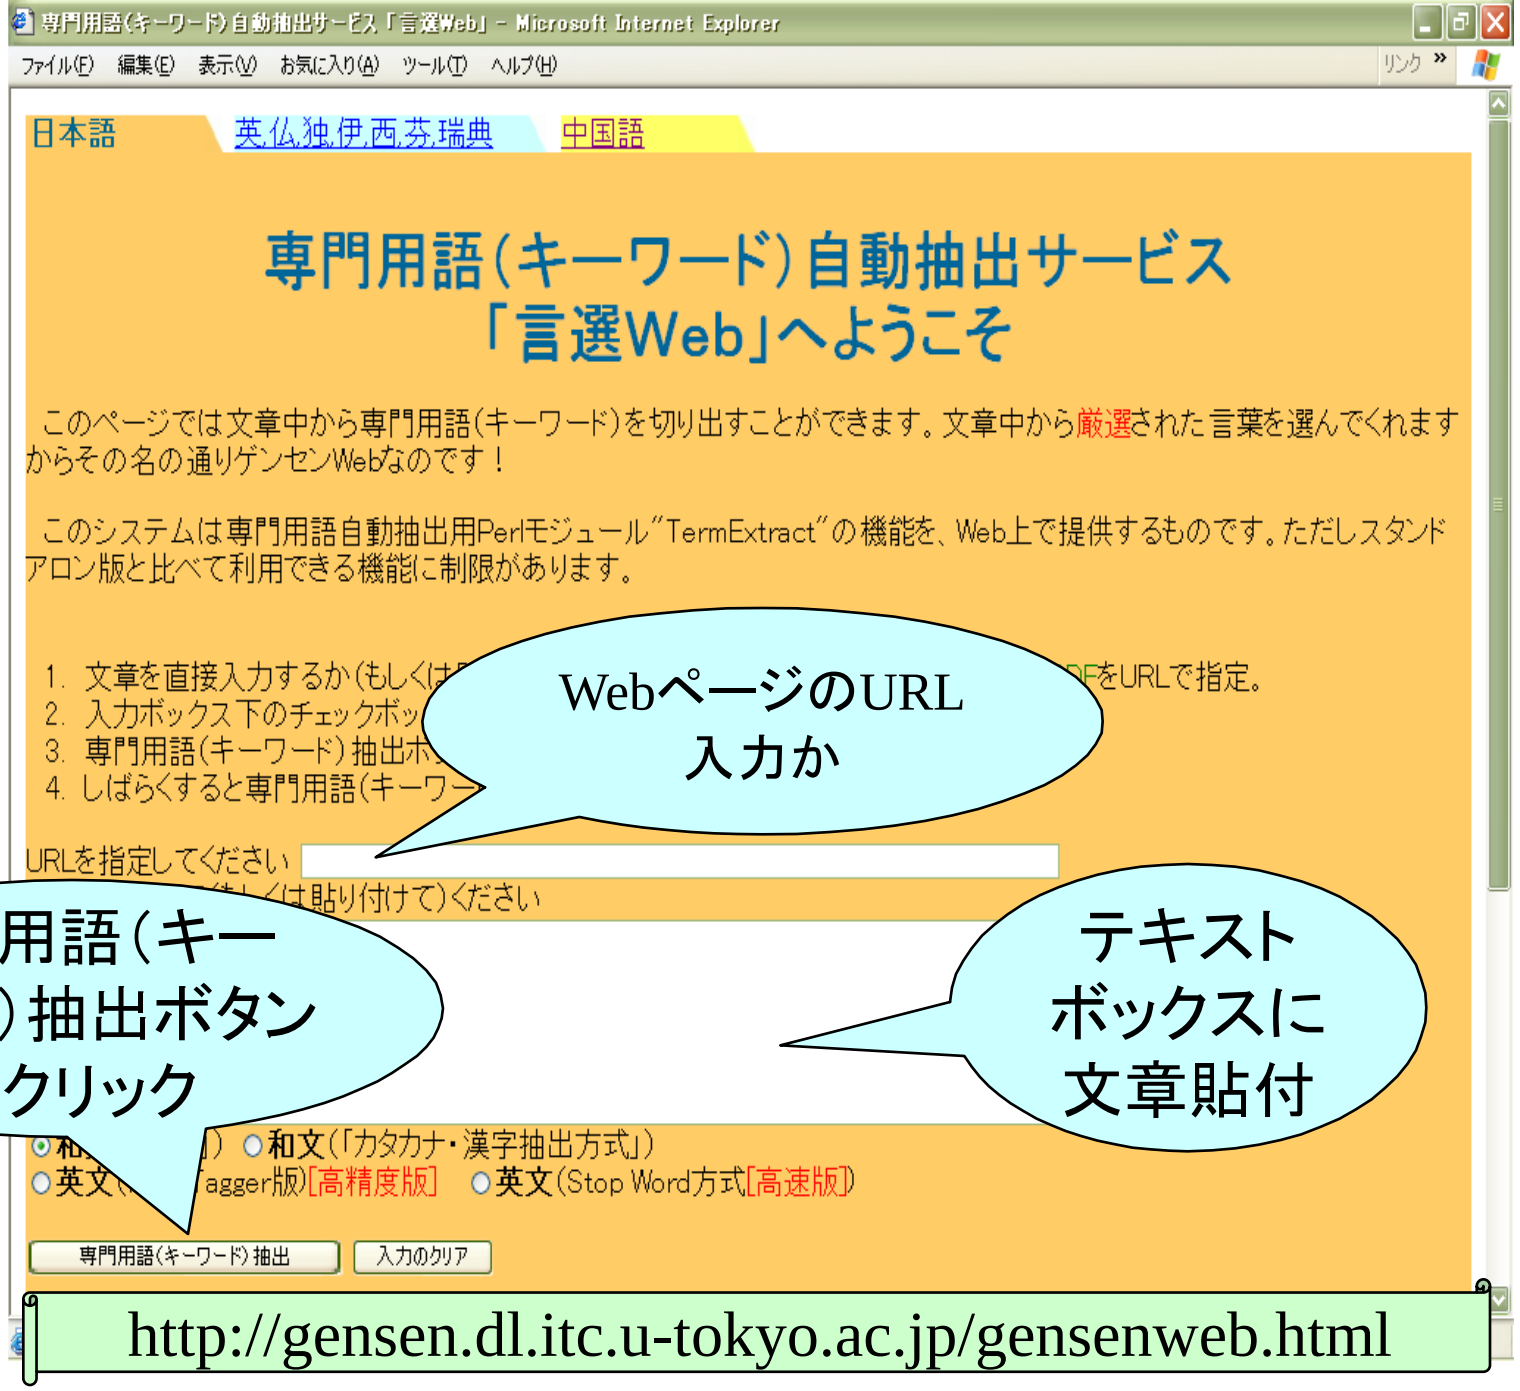
東京大学理学部　前田　朗
東京大学経済学部　小島　浩之
東京大学情報基盤センター　中川　裕志

平成17年9月29日（木）
於・横浜国立大学

テーマと発表概要

- テーマ
  - 専門用語自動抽出システム「言選Web」の中文版のエンジンを人民日報タグつきコーパスで評価する。
- 発表概要
  1. 「言選Web」とは
  2. 人民日報タグつきコーパスと評価方法
  3. 評価データと考察

言選Web（日本語版）

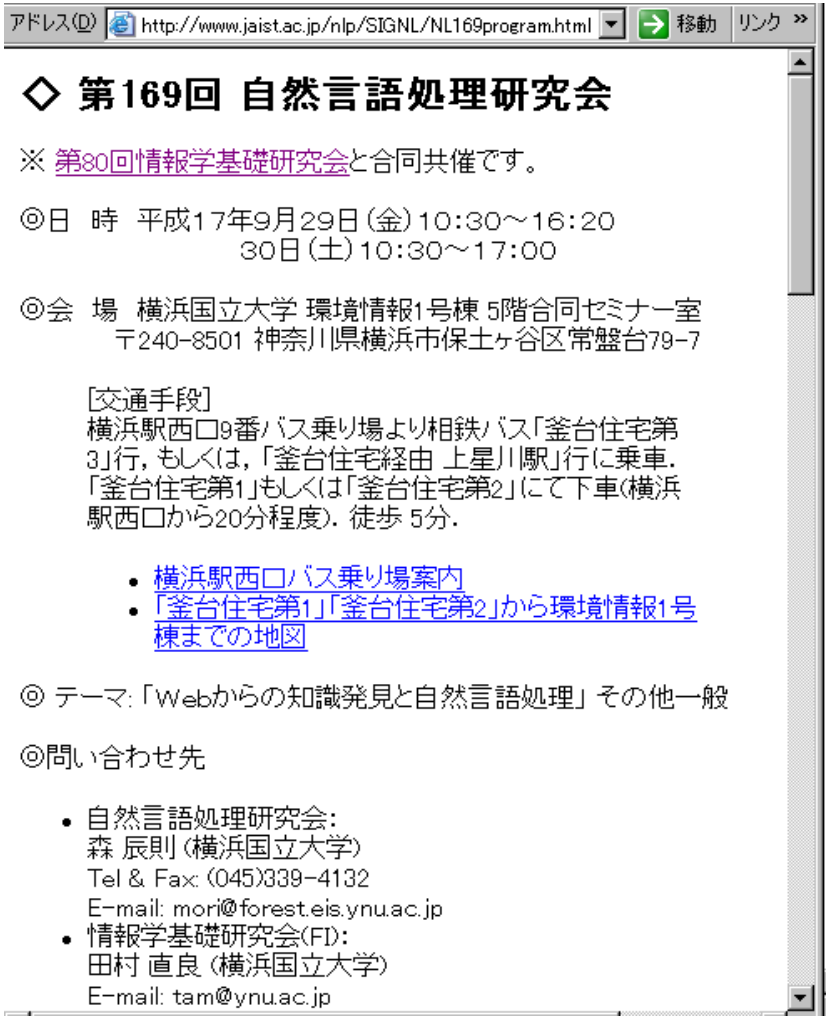


http://gensen.dl.itc.u-tokyo.ac.jp/gensenweb.html

「言選Web」処理結果例

第169回自然言語処理研究会のWebページ

http://www.jaist.ac.jp/nlp/SIGNL/NL169program.html



アドレス(D) http://www.jaist.ac.jp/nlp/SIGNL/NL169program.html 移動 リンク

◇ 第169回 自然言語処理研究会

※ 第80回情報学基礎研究会と合同共催です。

◎日　時　平成17年9月29日(金)10:30～16:20
30日(土)10:30～17:00

◎会　場　横浜国立大学 環境情報1号棟 5階合同セミナー室
〒240-8501 神奈川県横浜市保土ヶ谷区常盤台79-7

[交通手段]
横浜駅西口9番バス乗り場より相鉄バス「釜台住宅第3」行，もしくは，「釜台住宅経由 上星川駅」行に乗車．「釜台住宅第1」もしくは「釜台住宅第2」にて下車(横浜駅西口から20分程度)．徒歩 5分．

- 横浜駅西口バス乗り場案内
- 「釜台住宅第1」「釜台住宅第2」から環境情報1号棟までの地図

◎ テーマ:「Webからの知識発見と自然言語処理」その他一般

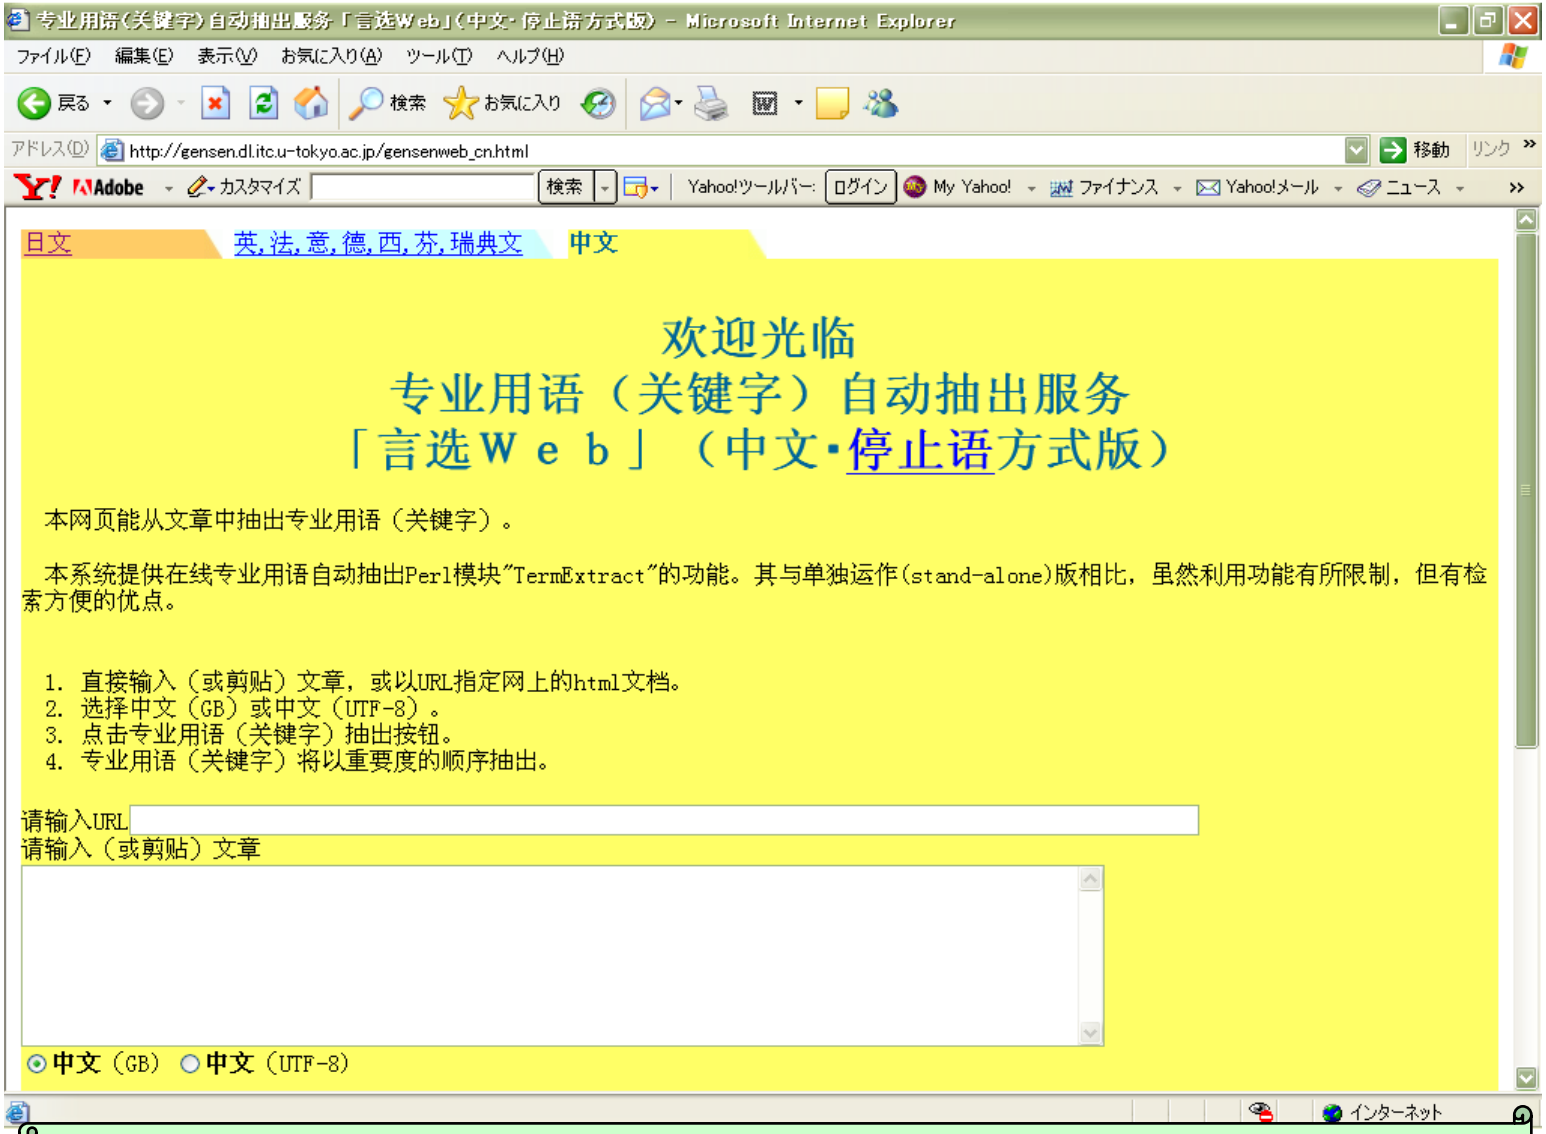
◎問い合わせ先

- 自然言語処理研究会:
森 辰則 (横浜国立大学)
Tel & Fax: (045)339-4132
E-mail: mori@forest.eis.ynu.ac.jp
- 情報学基礎研究会(FI):
田村 直良 (横浜国立大学)
E-mail: tam@ynu.ac.jp

上位語と重要度

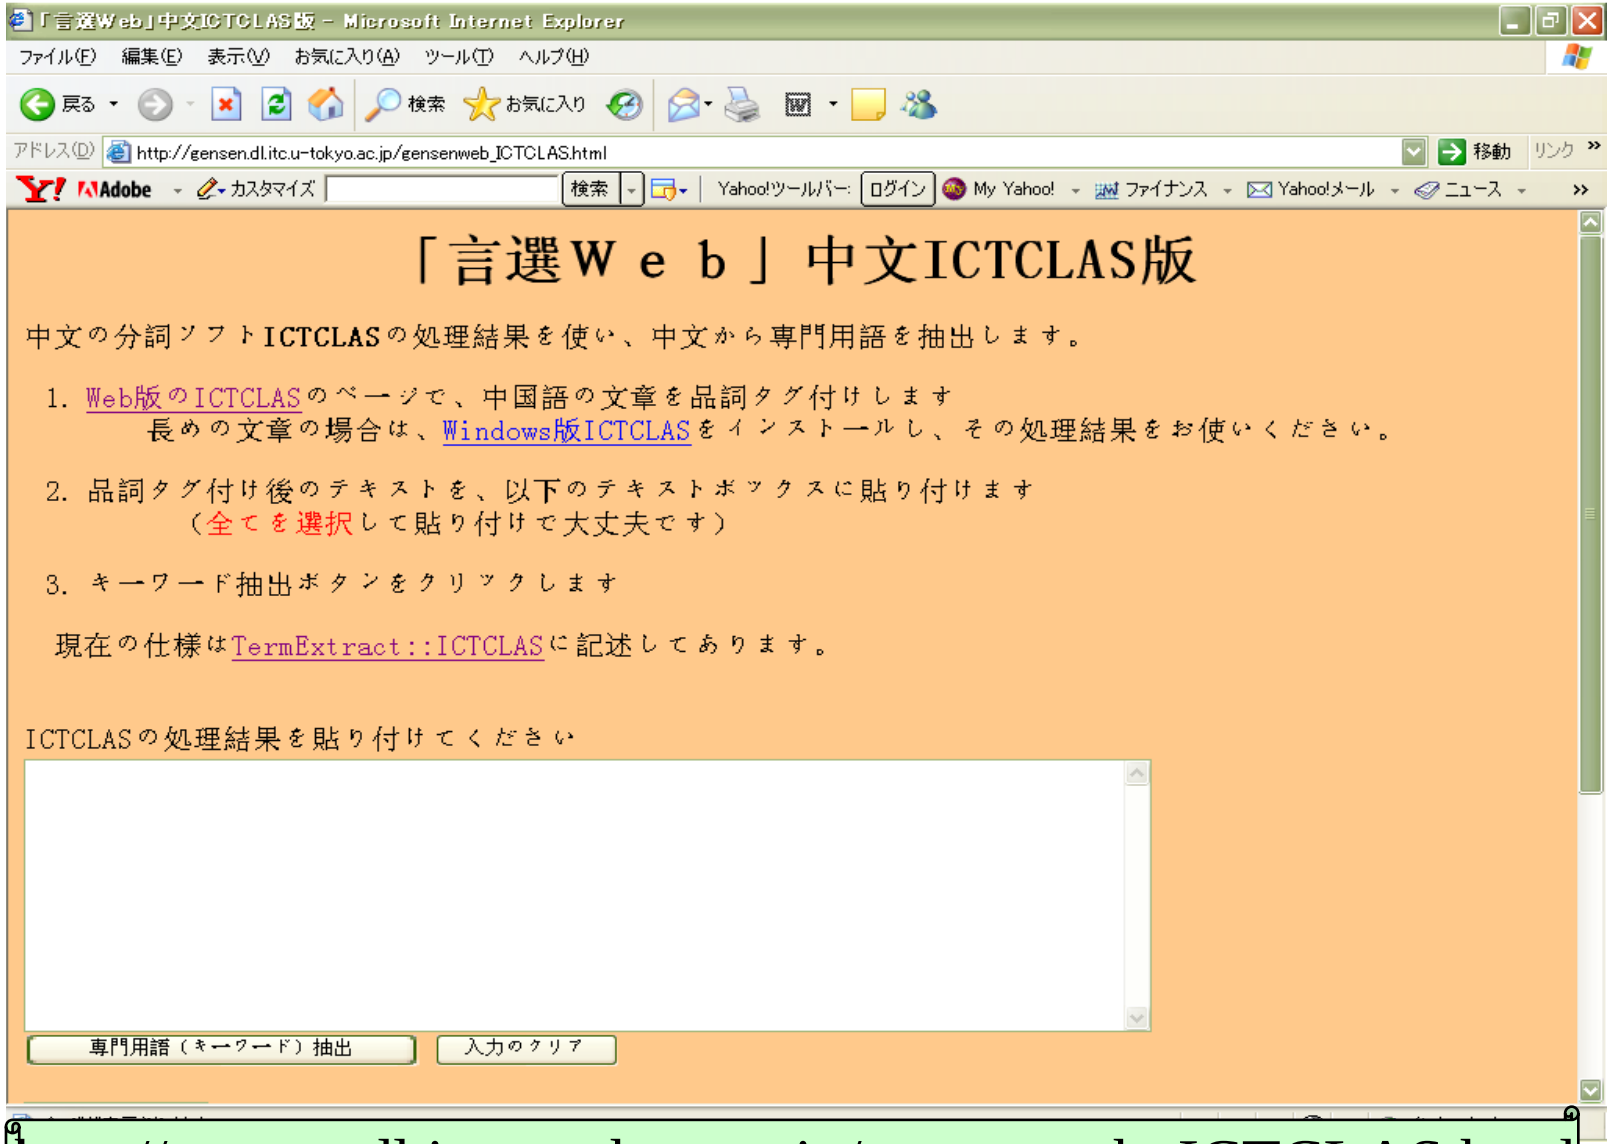
横浜国立大学大学院
　環境情報研究院(22.00)
横浜国立大学大学院
　環境情報学府(18.82)
釜台住宅(15.73)
自然言語処理研究会(14.09)
環境情報1(13.82)
質問応答(13.68)
森辰則(11.70)
抽出(11.62)
日(8.00)
情報学基礎研究会(7.69)
知識発見(7.54)
概念抽出(7.00)
翻訳(6.93)
自然言語処理(6.62)
…

「言選Web」中文・停止語方式版



http://gensen.dl.itc.u-tokyo.ac.jp/gensenweb_cn.html

「言選Web」中文ICTCLAS版

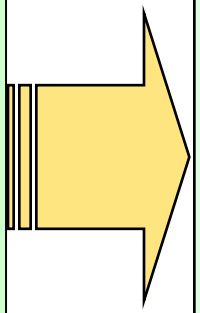


http://gensen.dl.itc.u-tokyo.ac.jp/gensenweb_ICTCLAS.html

中文ICTCLAS版処理結果例

ドーピング関係の記事

李铁映在全国体委主任会议上强强
坚持体育事业发展正确方针政策同使用兴兴兴行为进行坚决斗争
新华社北京１月１６日电（记者许基仁、李贺普）
中共中央政治局委员、国务委员李铁映今天在１９９８年全国体委主任会议上说，体育战战要认真学习、全面贯贯党的十五大精神，坚持体育事业 …



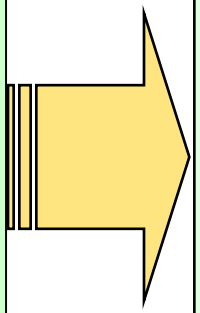
上位語と重要度

李铁映(20.78)
体育事业(19.28)
体育战战(13.82)
体育(9.49)
体育工作(8.11)
兴兴兴(7.94)
全国体委主任会议(4.73)
…

中文ICTCLAS版処理結果例

ドーピング関係の記事

李铁映在全国体委主任会议上强强
坚持体育事业发展正确方针政策同使用兴兴兴行为进行坚决斗争
新华社北京１月１６日电（记者许基仁、李贺普）
中共中央政治局委员、国务委员李铁映今天在１９９８年全国体委主任会议上说，体育战战要认真学习、全面贯贯党的十五大精神，坚持体育事业 …



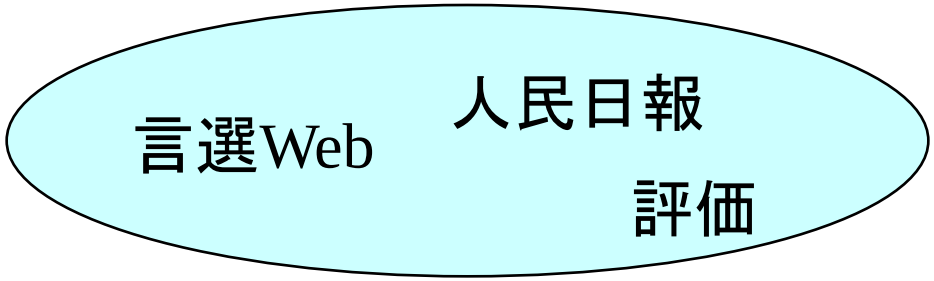
上位語と重要度

李铁映(20.78)
体育事业(19.28)
体育战战(13.82)
体育(9.49)
体育工作(8.11)
兴兴兴(7.94)
全国体委主任会议(4.73)
…

２つの重要な機能

言選Webを人民日報で評価する….

Step 1 用語候補抽出



Step 2 用語候補の重要度順ランキング

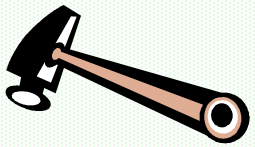
一位: 言選Web，二位: 人民日報，三位: 評価

「言選Web」における用語候補抽出２方式

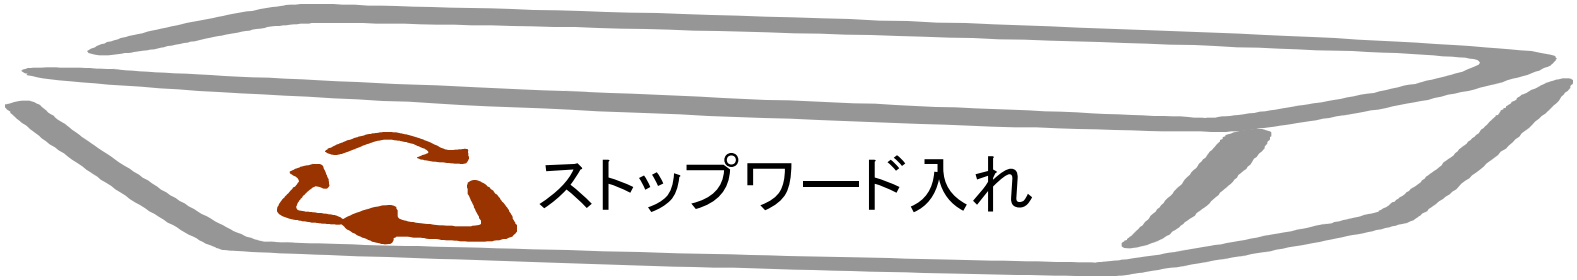
- ストップワード方式
  - 人手により用意したストップワードで文章分割
  - １～２字のストップワード選定が性能に影響
  - 形態素解析器に依存しない
  - カスタマイズが容易
- ICTCLAS方式
  - 形態素解析器の処理結果を利用
  - 文法書を参考に用意したルールを使用
  - 形態素解析器に依存

ストップワード方式

用語候補



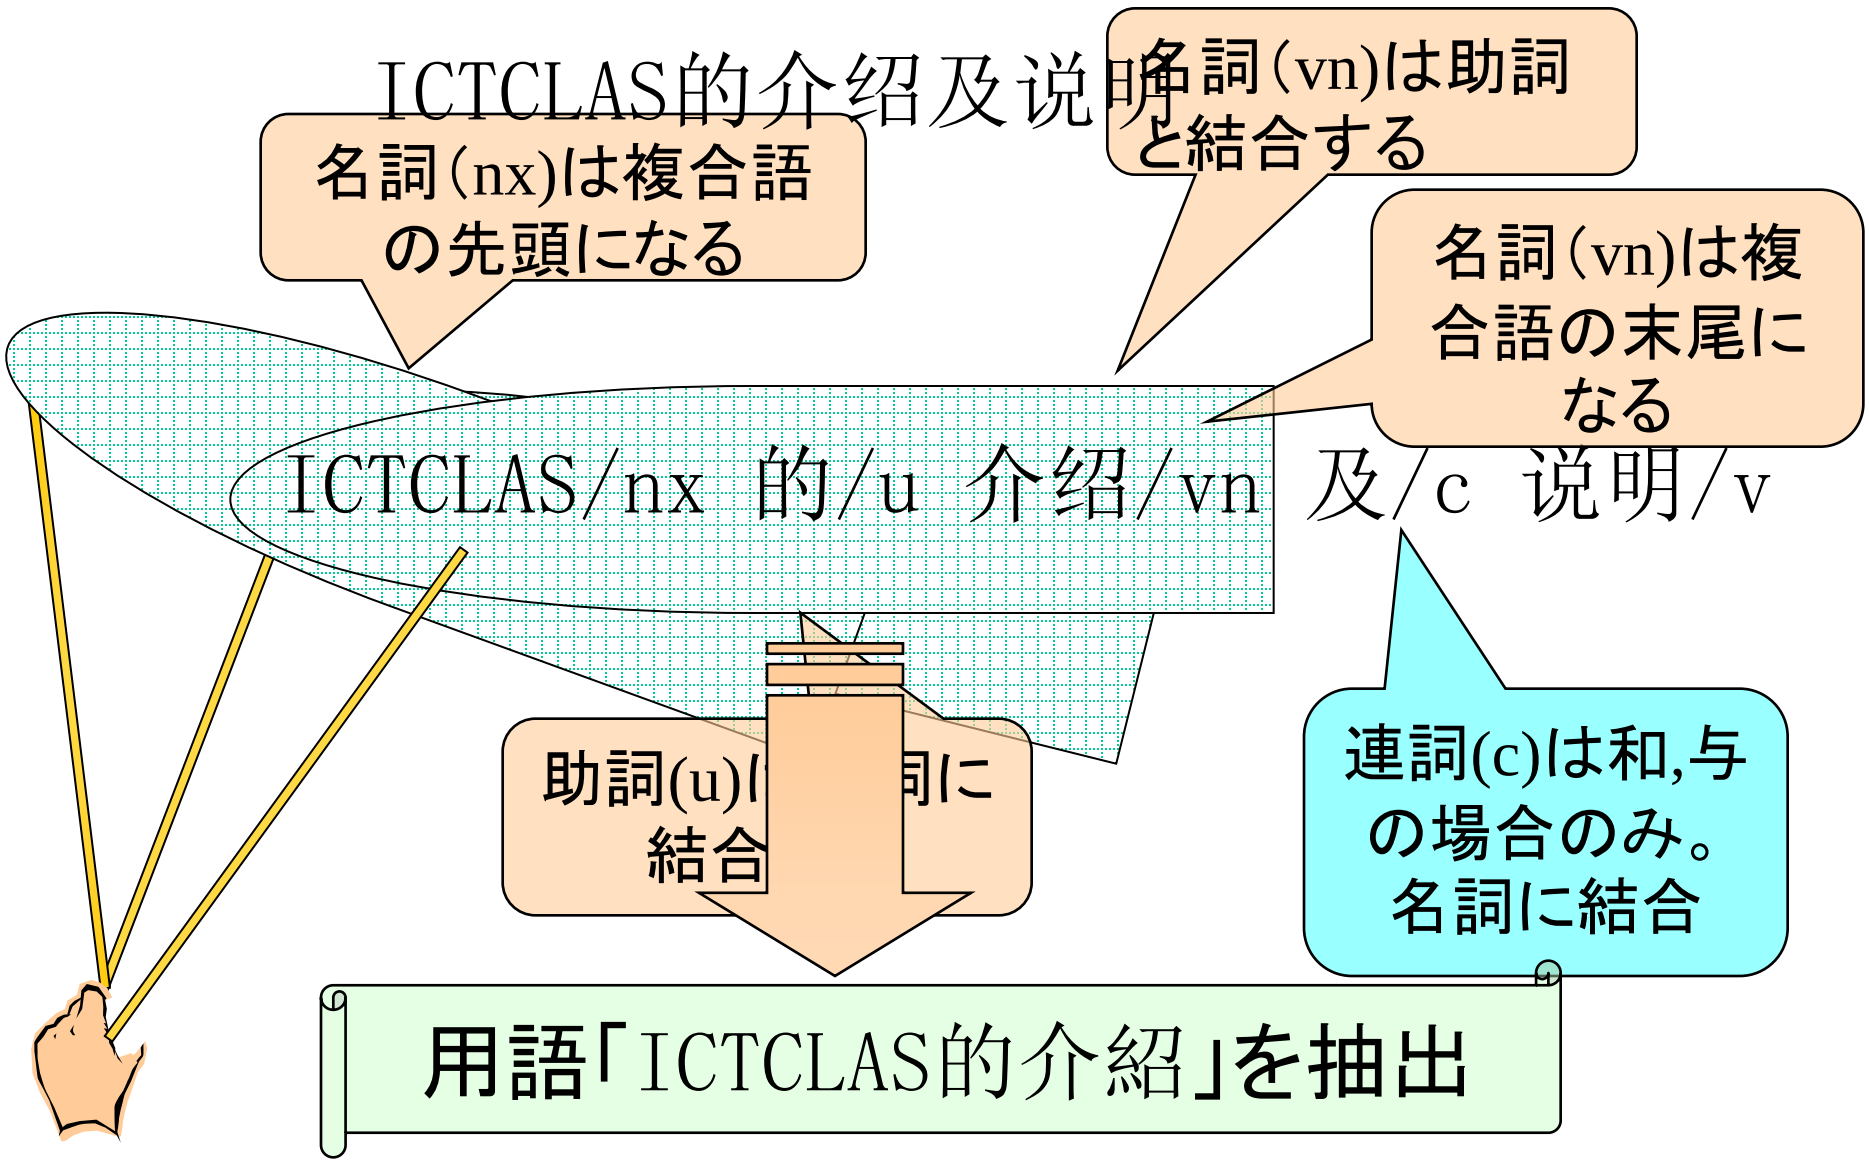
中国的互联网已经四通八达了



ICTCLAS方式

- 名詞に類する語(ng n nr ns nt nz nx vn an i j) *以後「名詞」
  - 名詞,形容詞,助詞,後接成分,連詞（和,与）に結合。
  - 複合語の先頭及び終端になる
- 形容詞(ag a)
  - 形容詞,助詞,後接成分,連詞（和,与）に結合。
  - 複合語の先頭になる
- 助詞(u), 後接成分(k)
  - 名詞,形容詞に結合
- 連詞(c)
  - 和,与の場合のみ。名詞に結合。
- 区別詞(b)
  - 名詞, 助詞,連詞（和,与）に結合。複合語の先頭になる

ICTCLAS方式２


ICTCLAS的介绍及说明
名詞(nx)は複合語の先頭になる
名詞(vn)は助詞と結合する
名詞(vn)は複合語の末尾になる
ICTCLAS/nx 的/u 介绍/vn 及/c 说明/v
助詞(u)は
結合
連詞(c)は和,与の場合のみ。名詞に結合
用語「ICTCLAS的介紹」を抽出

言選Webのエンジンで可能な用語候補重要度計算手法

- FLR
  - 単語FLR、文字FLR
- LR
  - 単語LR、文字LR
- Frequency, TF
- TF*IDF



LRとFLR

複合語は単名詞からなる
(例 情報処理学会 → {情報, 処理, 学会})

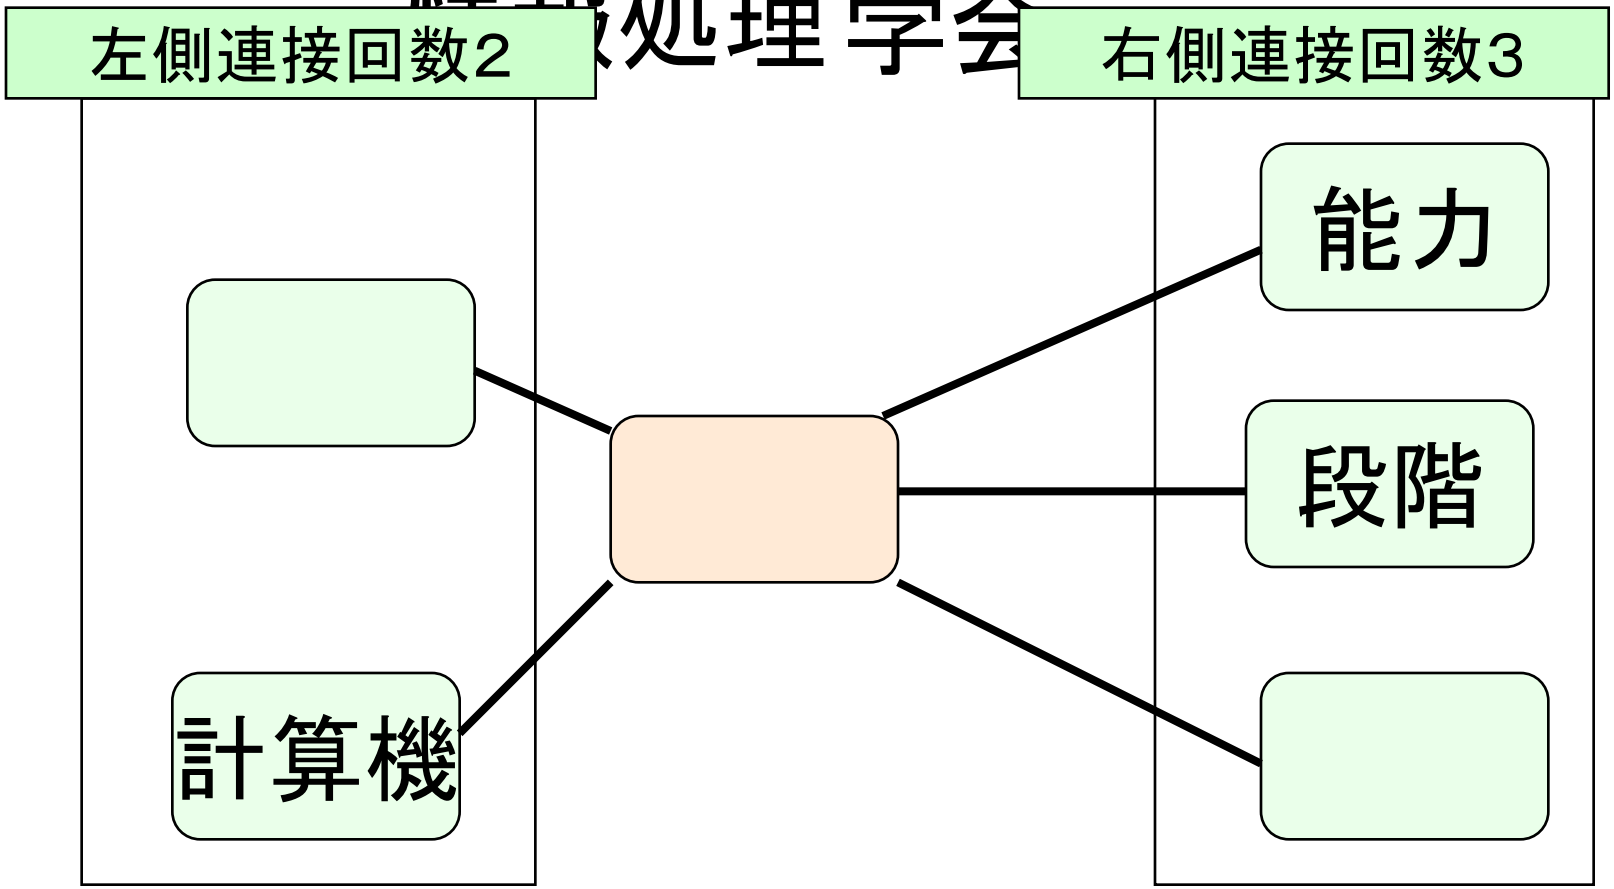
他と連接して複合語をなすような単名詞こそ、まさに文中の核となる概念を示している

LRは用語を構成する単名詞の連接が多いほど、高い重要度を与る。

FLRはLRに対して、さらに文中の用語出現頻度を掛け合わせる

単語LR(FLR)

情報処理学会



中国語と文字LR(FLR)

他と連接して複合語をなすような単語こそ、
まさに文中の核となる概念を示している

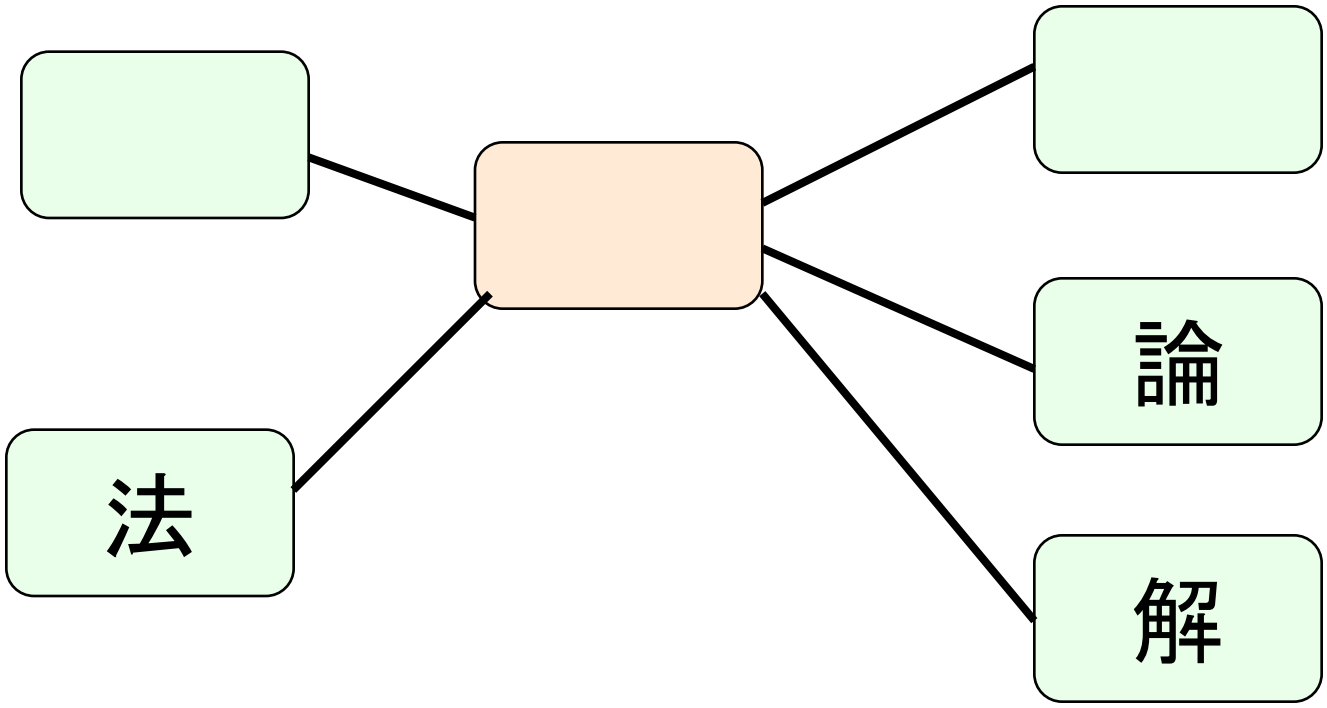
漢字は1字が概念を表す表意文字

中国語の場合、LR(FLR)を文字で行うことも可能

単語を文字に変えても
成り立つ

文字LR(FLR)

情 報 処 理 学 会



LRとFLRの計算式

- 用語Wを単名詞w_iのリスト$W=\{ w_1, \ldots , w_n\}$とする
- $L(w_i)$ = 単名詞w_iの左側連接回数＋１
- $R(w_i)$ = 単名詞w_iの右側連接回数＋１
- 複合名詞$W=\{ w_1, \ldots , w_n\}$の重要度LRは次式となる。

$$LR(W) = \left[\prod_{i=1}^{n} L(w_i) \times R(w_i) \right]^{1/2n}$$

複合名詞Wの出現頻度を $F(W)$ とするとFLRは次式で定義される。

$$FLR = F(W) \times LR(W)$$

TF(Term Frequency)とFrequency

情報と情報システム

- TF (Term Frequency)

  → **「情報」2回**, 「情報システム」1回

- Frequency

  → **「情報」1回**, 「情報システム」1回

TF*IDF

TF*IDFは次式で算出している

$$TF * IDF = TF \times \log\left(\frac{\text{総文書数}}{\text{該当の用語を含む文書数}} + 1\right)$$

２．人民日報タグつきコーパスと「言選Web」評価手法

I. 人民日報タグつきコーパス
II. 評価方法概要
III. 正解語（第1種正解語と第2種正解語）
IV. 機械学習による第1種正解語の用語候補抽出
V. 評価尺度

人民日報タグつきコーパス

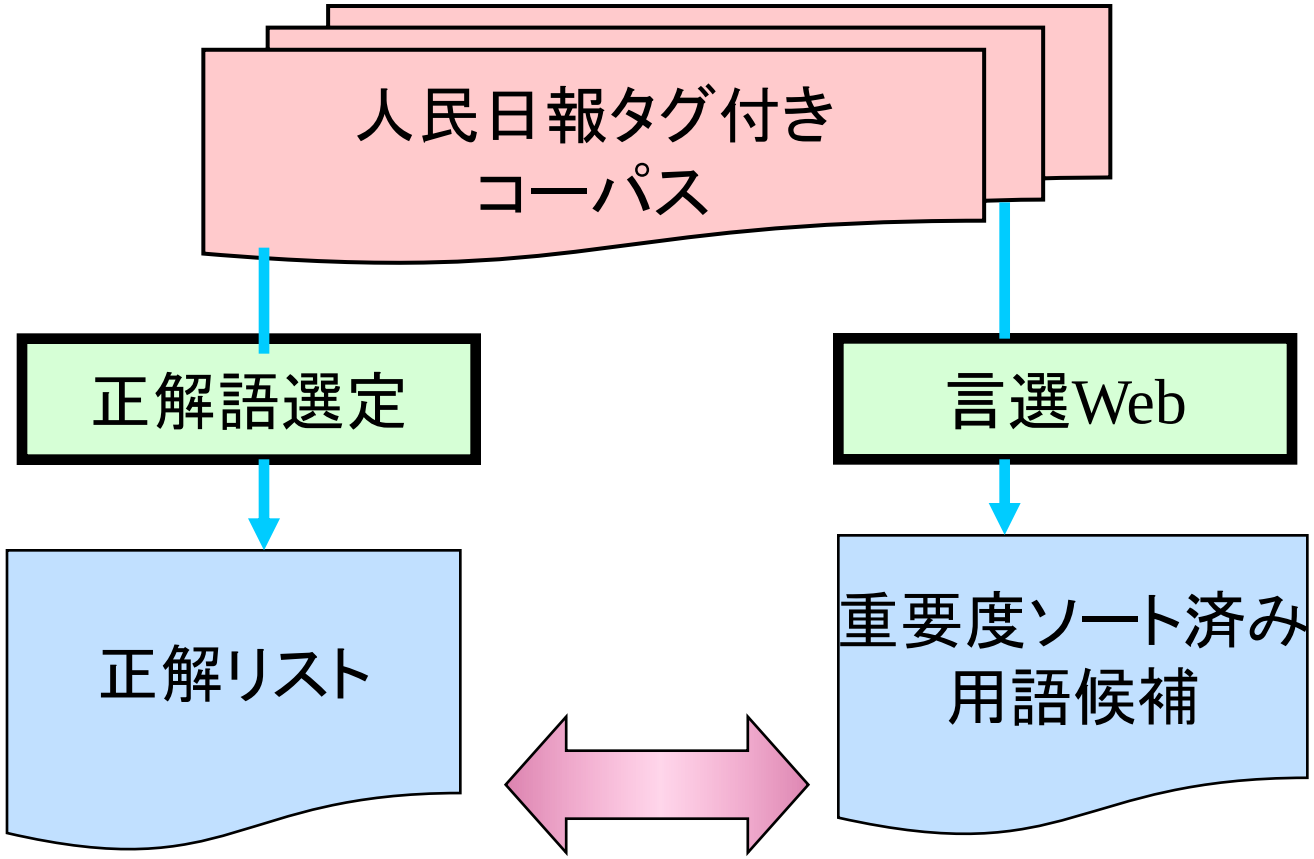
1998年1月分
3,055記事

単語分割＋
品詞情報付与済

19980117-02-003-003/m 新华社/nt 北京/ns 1 月/t １６日/t 电/n （/w 记者/n 许/nr基仁/nr 、/w 李/nr 贺普/nr ）/w[中共中央/nt 政治局/n]nt 委员/n 、/w国务委[illegible]/nr 今天/t 在/p [illegible] １９９８年/t [illegible] 会议/n上/f 说/v …

一部の複合語は、[ ] で括られた上、品詞情報が付与されている

「言選Web」評価方法概要



再現率、適合率、平均適合率で評価

第1種正解語

人民日報タグつきコーパス中の

[ ] で括られた複合語（選定基準不明）

組織名と地名が 96% を占める

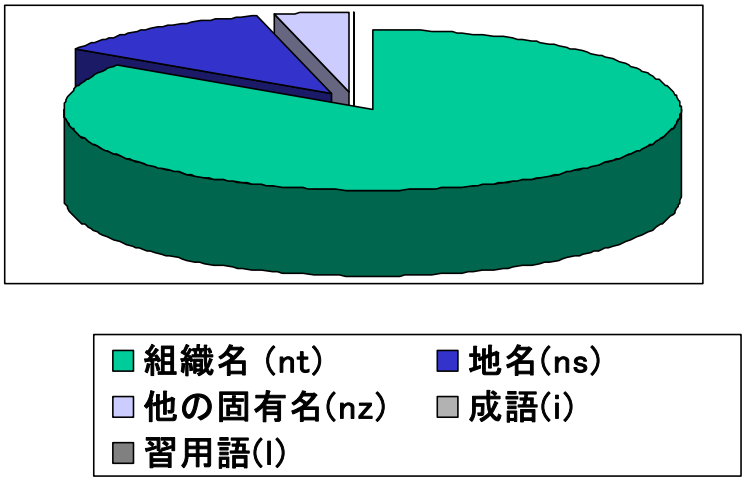
組織名と地名は記事中における
専門用語とも捉えることができる

第1種正解語として評価に用いる

第1種正解語内訳

品詞(タグ)	出現回数	割合
組織名 (nt)	7,381	84.5%
地名(ns)	1,015	11.6%
他の固有名(nz)	327	3.7%
成語(i)	7	0.1%未満
習用語(l)	3	0.1%未満
計	8,733	

第1種正解語では組織名と地名で実に96%を占める！！



全3,055記事、 1記事あたりの正解語数2.86

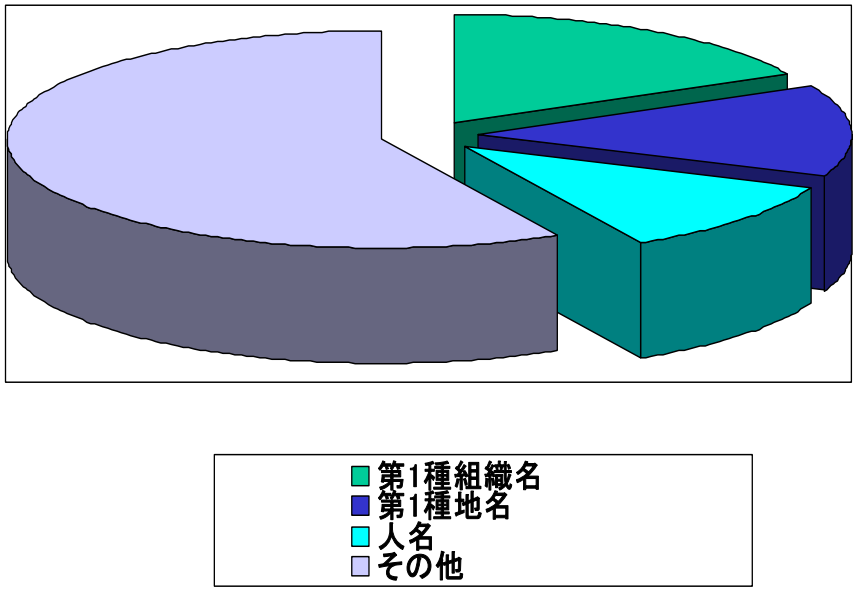
第2種正解語

個別の記事の内容を端的に示す語を中心に、人手によりコーパスから選定

i. 原則として複合名詞（句）
ii. 組織名、地名、人名は、記事のトピックとして差し支えない限りにおいて選定する。
iii. 選定したキーワードが文章中で、省略語や 同義語に言い換えられた語も選定する。

第2種正解語内訳

品詞	出現回数	割合
第1種組織名	392	14.9%
第1種地名	304	11.6%
人名	246	9.3%
その他	1,286	64.2%
計	2,628	



全229記事　1記事あたりの正解語数11.48

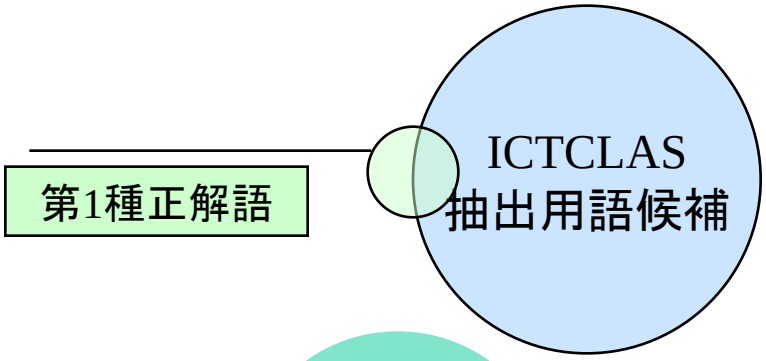
第2種正解語の「その他」とは

- 第1種正解語以外の地名、組織名
- 事件名（「ドーピング」など）
- 役職名
- イベント名称
- 特殊な事物（インターネット用語など）
- 上記全ての別表現・省略表現

など

「言選Web」の用語候補抽出手法は第1種正解語に向かない

ICTCLAS方式の例（ストップワード方式も同様の傾向）



再現率は約50%だが、適合率が2.31%と低い

適合率の低さは第1種正解語の正解数と、
組織名+地名で96%を占めることによる

決定木による用語候補の抽出

第1種正解語（半月分）を教師データとする

＋

当該単語の前後２単語の品詞情報を利用する

＋

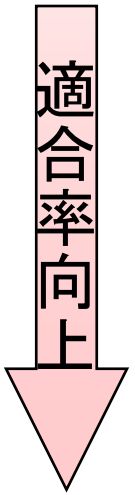
用語候補が正解語の先頭S，末尾Eであるかどうかを判断する決定木をC4.5で学習する

（評価データには教師データに使わなかった
残り半月分の1,572記事を用いる）

決定木による用語候補抽出手法(負例)

正例(19、334例)に一定量の負例を加え、
再現率を犠牲にしない範囲で適合率を向上させる

負例の数	再現率(%)	適合率(%)	F値
0	78.76	7.31	13.38
10,000	74.80	15.57	25.77
20,000	73.81	23.90	36.11
30,000	73.16	24.82	37.06



負例を20,000で抽出した用語候補を採用

評価に使用するデータ(まとめ)

A. 用語候補

決定木で抽出した用語候補

ストップワード方式により抽出した用語候補

ICTCLAS 方式により抽出した用語候補

B. 正解リスト

第1 種正解語(コーパス付属の正解語・1,572記事)

第2 種正解語(記事の内容を端的に表す語・229記事)

再現率・適合率・平均適合率

1. 正解用語数を$|D_q|$ とする
2. 用語リストの重要度ランク上位k語めが正解とマッチした場合に=1,マッチしない場合　→　=0とする。
3. 第k位までを対象にした場合の再現率と適合率は次の式で求められる。

$$\text{適合率}(k) = \frac{1}{k} \sum_{1 \le i \le k} r_i \qquad \text{再現率}(\mathrm{k}) = \frac{1}{|D_q|} \sum_{1 \le i \le k} r_i$$

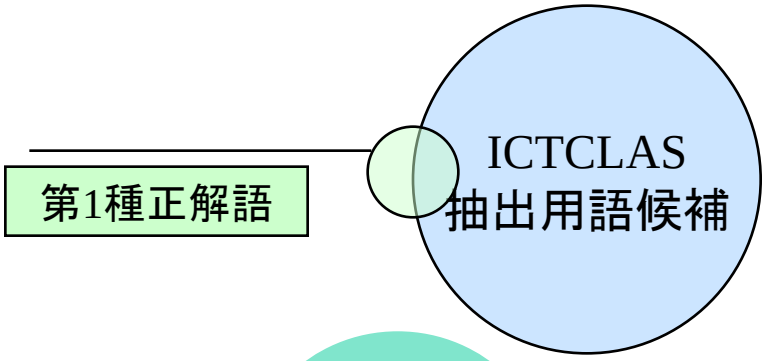
$$\text{平均適合率} = \frac{1}{|D_q|} \sum_{1 \le k \le N} r_k \times \quad \text{適合率}(k)$$

*Nは正解が最後に現れた順位

第1種正解語での評価

「言選Web」の用語候補抽出手法は第1種正解語に向かない

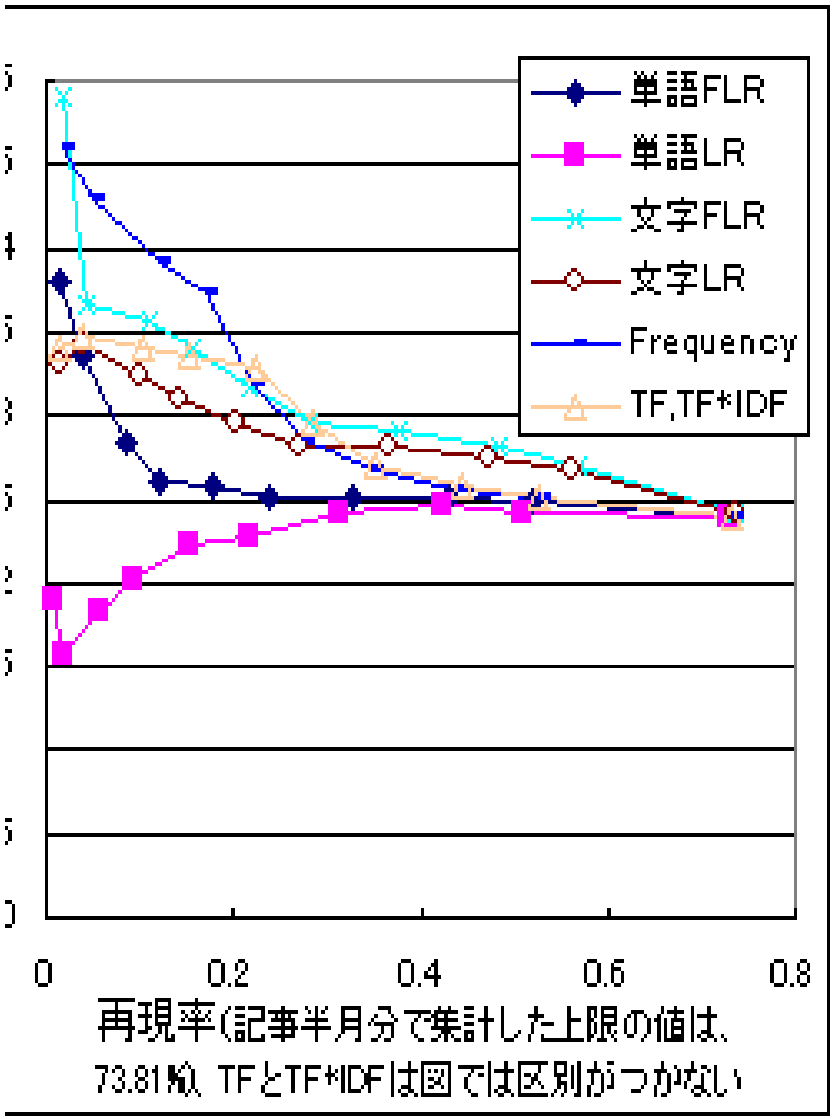
ICTCLAS方式の例（ストップワード方式も同様の傾向）

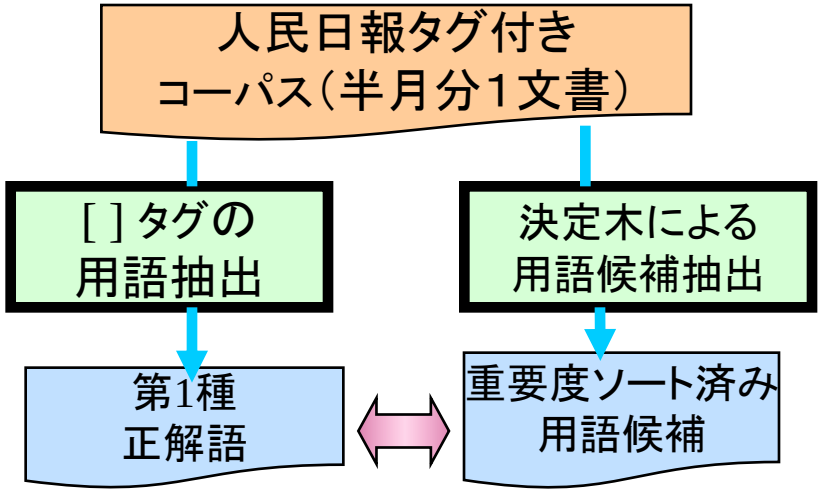


再現率は約50%だが、適合率が2.31%と低い

適合率の低さは第1種正解語の正解数と、
組織名+地名で96%を占めることによる

第1種正解語・記事半月1文書(結果)





重要度計算方式	平均適合率(%)
単語FLR	19.39
単語LR	19.39
文字FLR	22.58
文字LR	21.11
Frequency	22.27
TF	21.15
TF*IDF	21.09

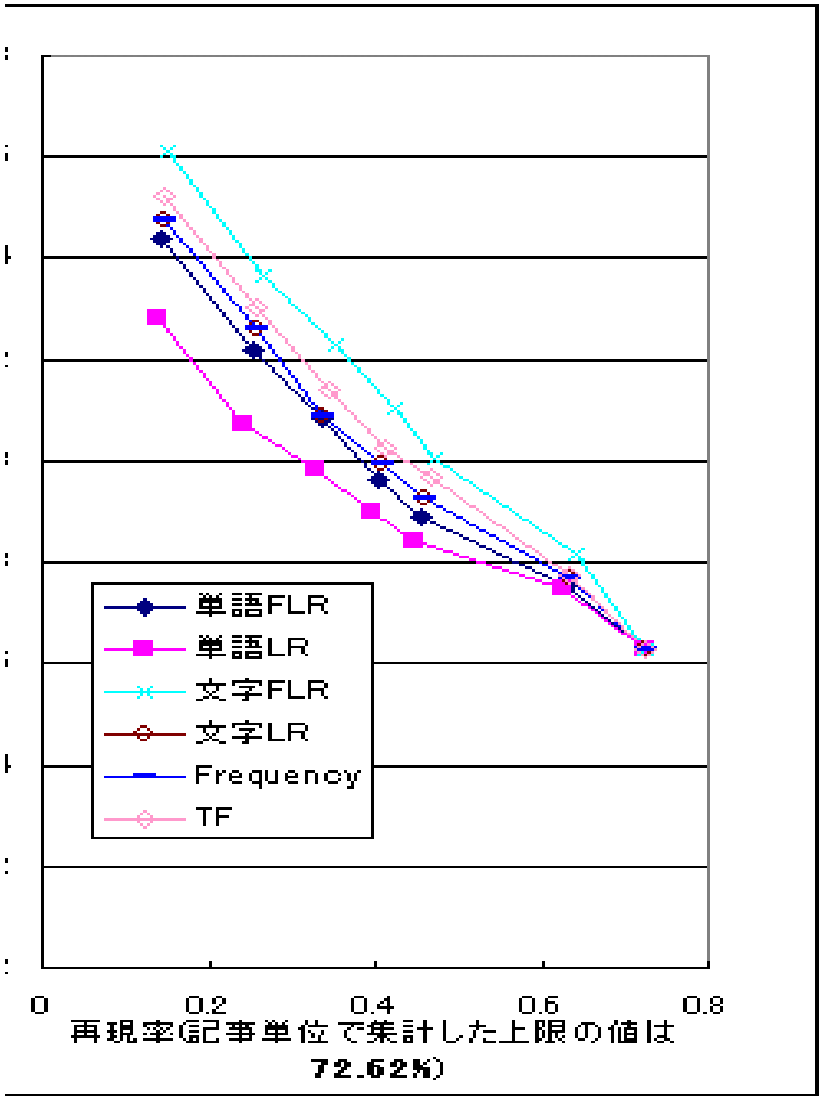
第1種正解語・記事全体（考察）

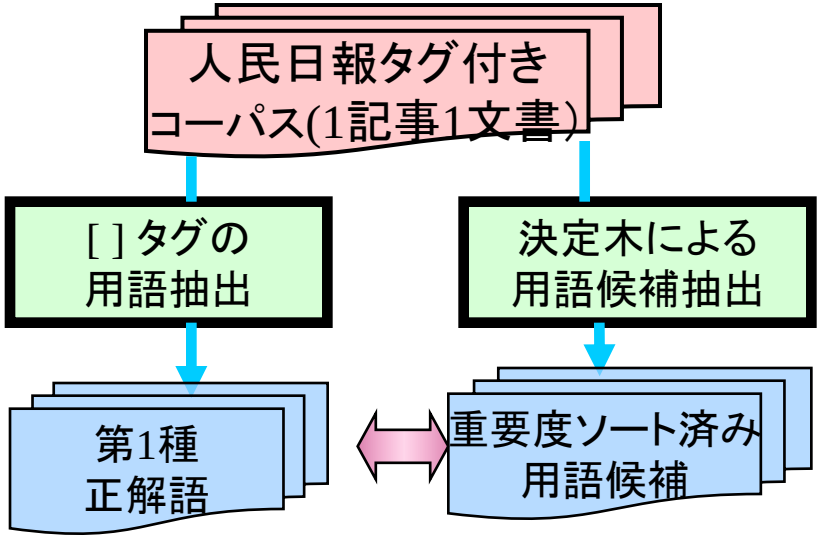
文字FLRとFrequencyが優良

単語LRは上位に普通名詞的な語が多いため、
上位が正解語と適合しない

逆に、文字FLRとFrequencyは
上位に普通名詞的な語が少ないと考えられる

第1種正解語・1記事1文書（結果）





重要度計算方式	平均適合率(%)
単語FLR	34.16
単語LR	33.61
文字FLR	35.84
文字LR	35.59
Frequency	34.58
TF	34.84

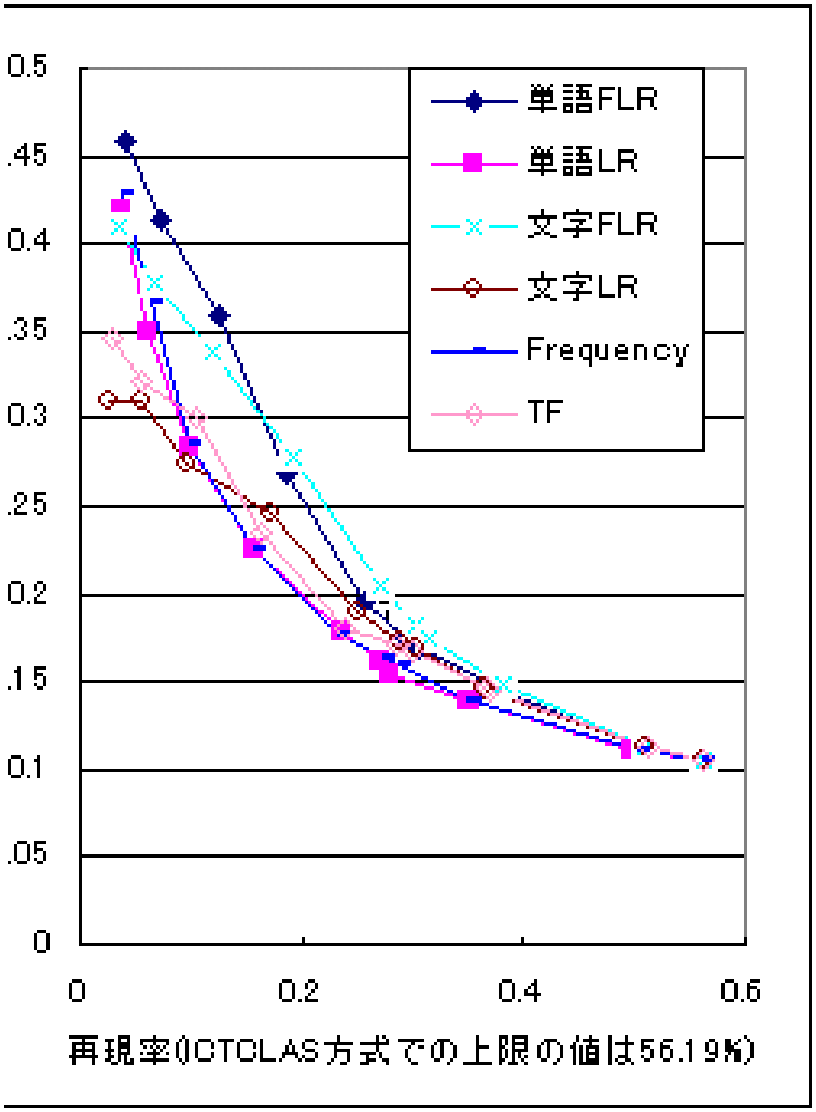
第1種正解語・決定木による用語候補抽出（考察）

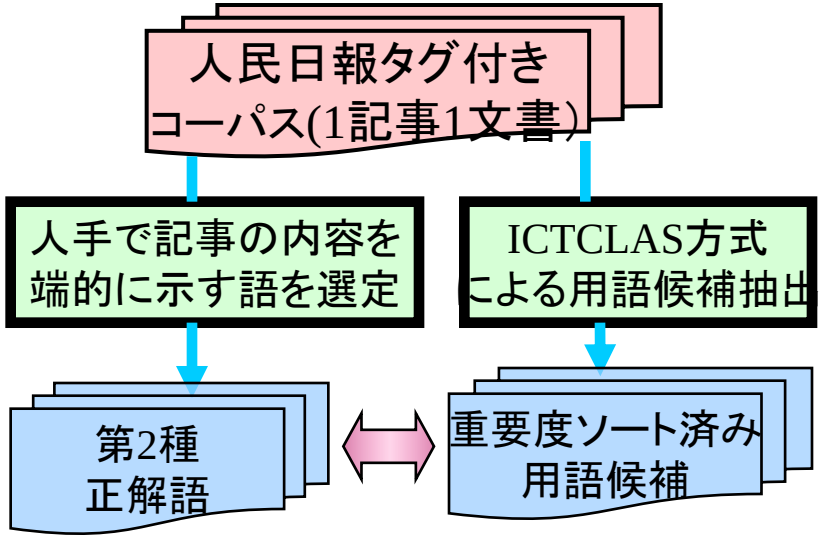
- 第1種正解語と決定木による用語候補抽出の組み合わせでは、文字FLRが優良。Frequency,TFがそれに次ぐ。

- 単語LRは、1記事1文書でこそ成果を発揮する。（そのため以降の評価は全て1記事1文書で行う）

第2種正解語での評価

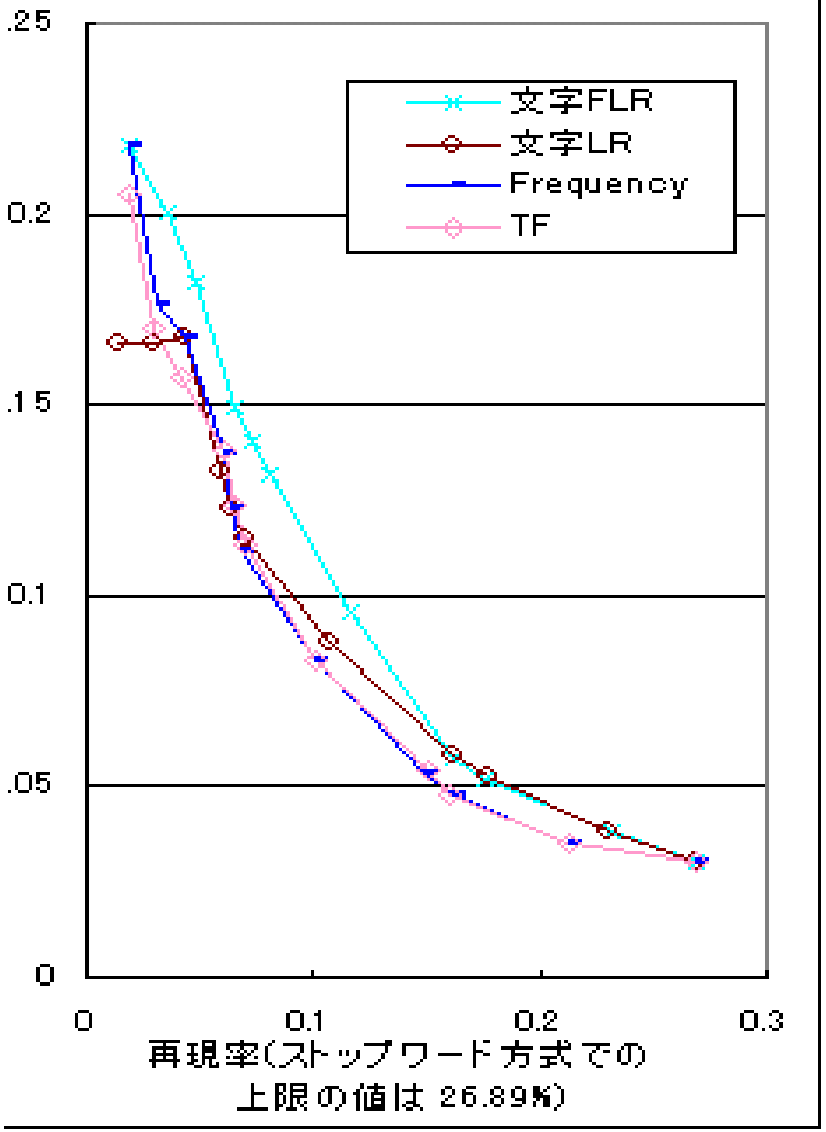
第2種正解語・1記事1文書ICTCLAS

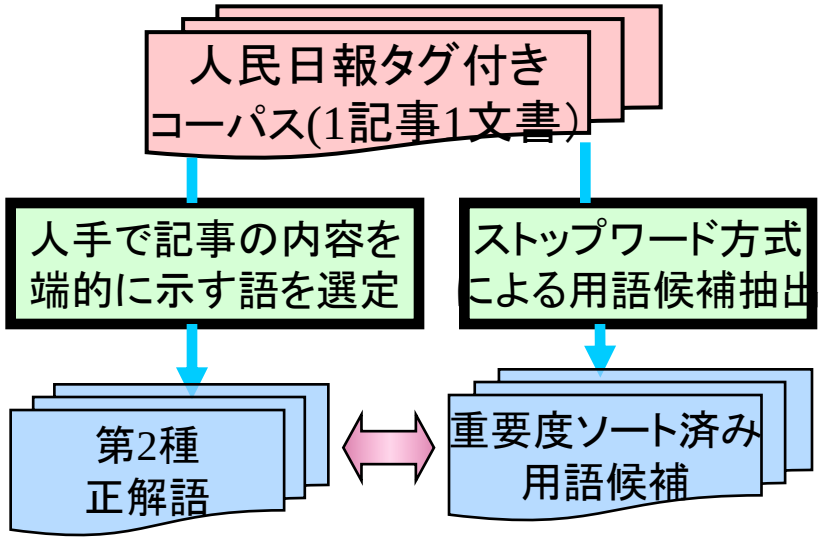




重要度計算方式	平均適合率(%)
単語FLR	23.49
単語LR	21.26
文字FLR	23.37
文字LR	21.20
Frequency	19.19
TF	19.11

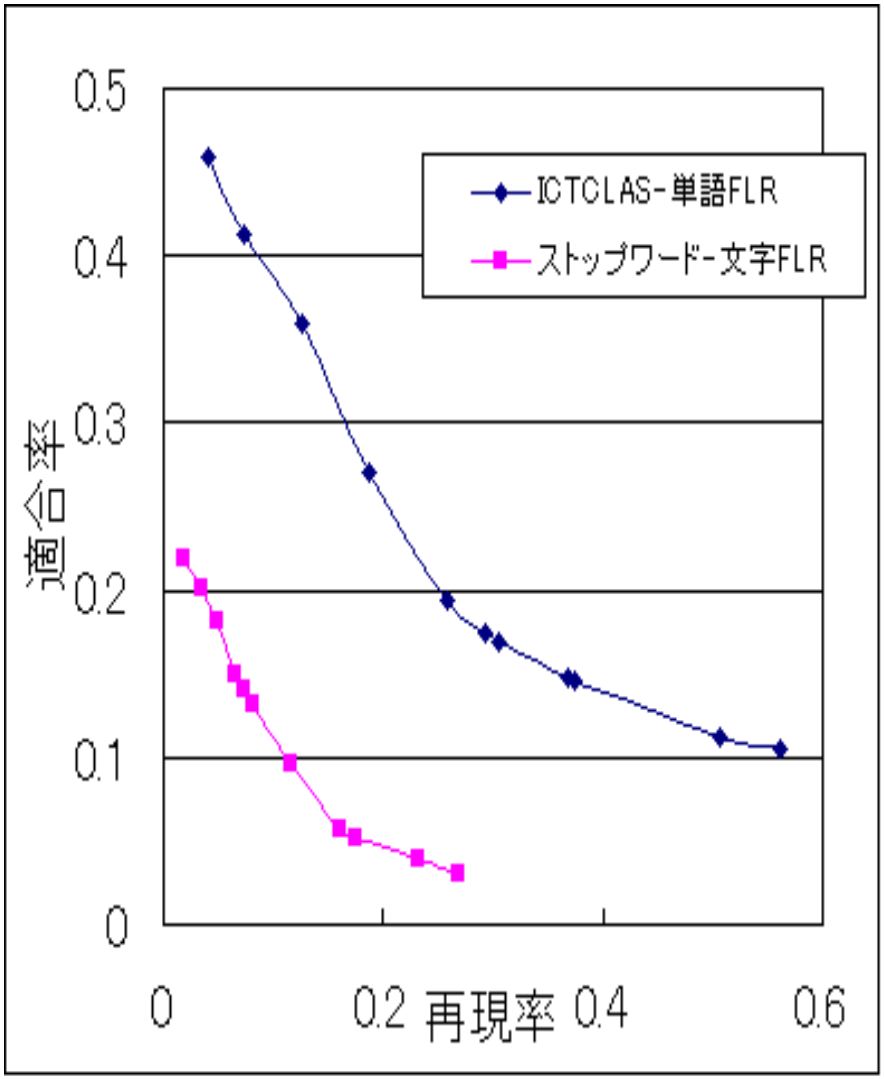
第2種正解語・1記事1文書ストップワード





重要度計算方式	平均適合率(%)
文字FLR	7.54
文字LR	6.49
Frequency	6.60
TF	6.41

ICTCLAS方式とストップワード方式の比較



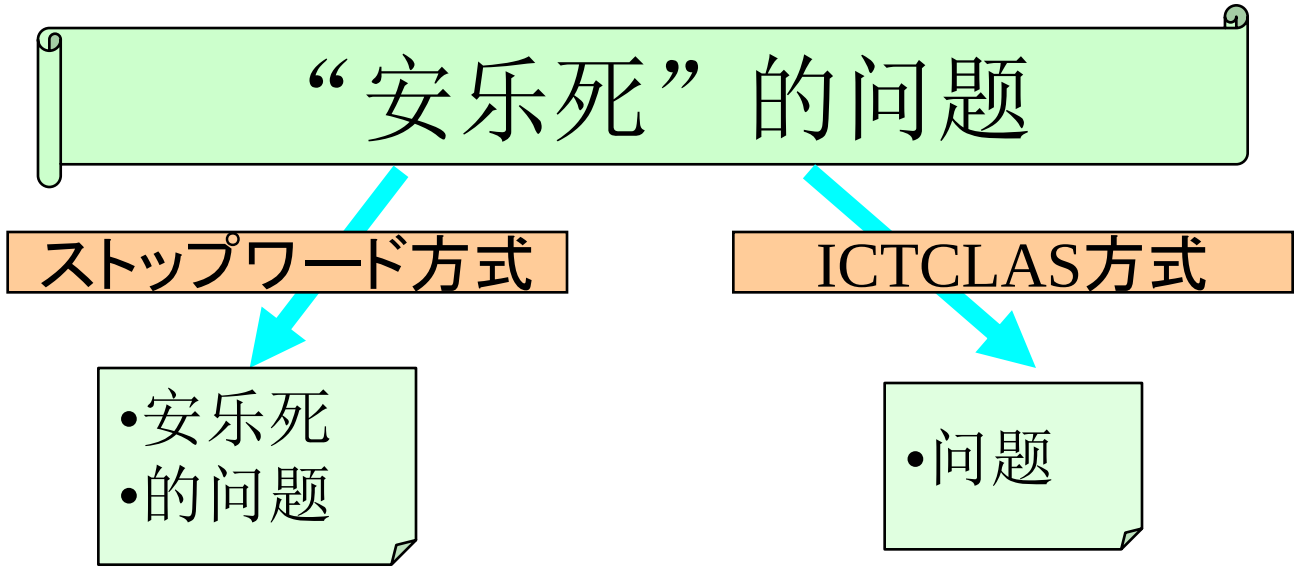
ICTCLAS方式が優位

平均適合率で約3倍

再現率上限で約2倍

方式	平均適合率(%)
ICTCLAS-単語FLR	23.49
ストップワード-文字FLR	7.54

ストップワード方式が有効なケース



ストップワード方式では

“安乐死”を抽出できる(ICTCLAS方式では動詞のため不可)

“问题”自体は抽出できないが、”问”,”题”の重要度が高くなり、文中の他の箇所で抽出された”问题”が上位になりやすくなる。

第2種正解語の組織名と地名を用いての比較

第1種正解語・
決定木による学習 → 文字FLRと
用語出現頻度が優良

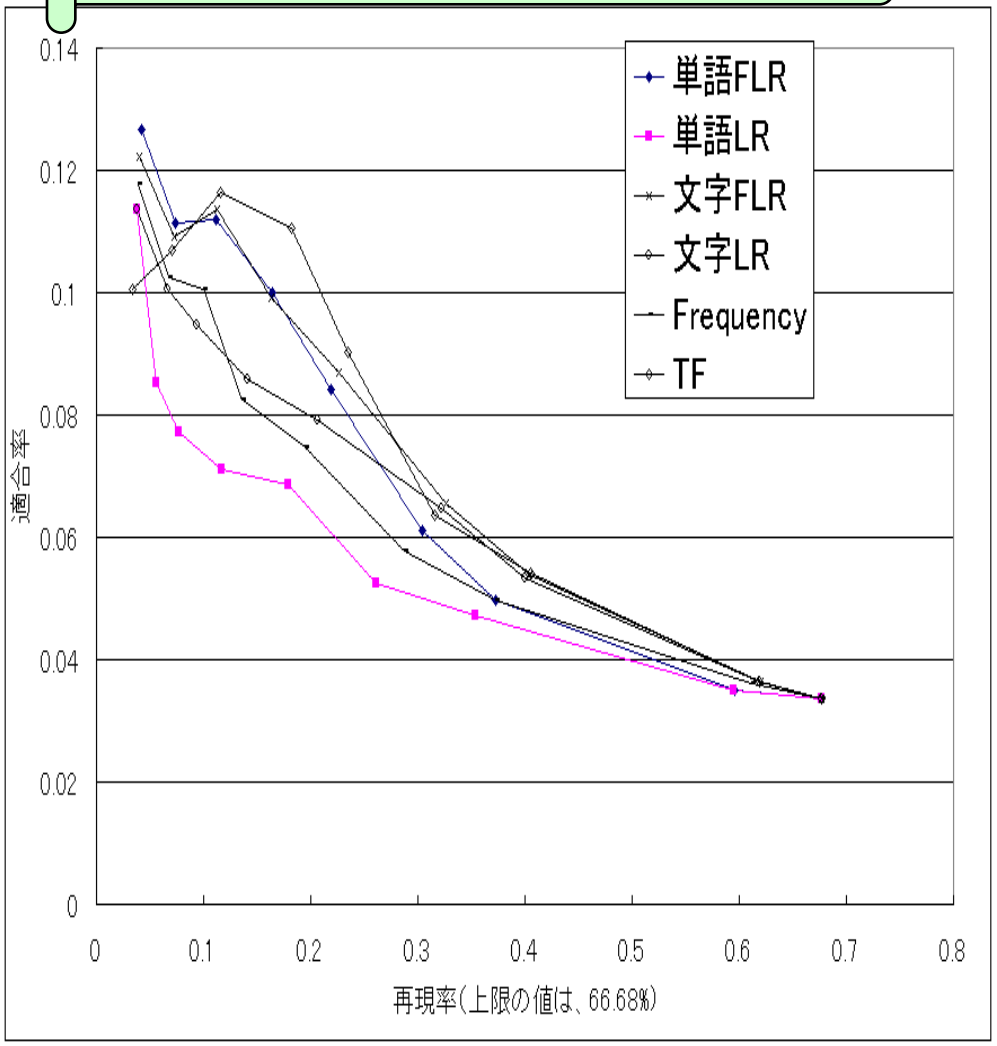
第2種正解語・
ICTCLAS方式 → 単語FLRが優良

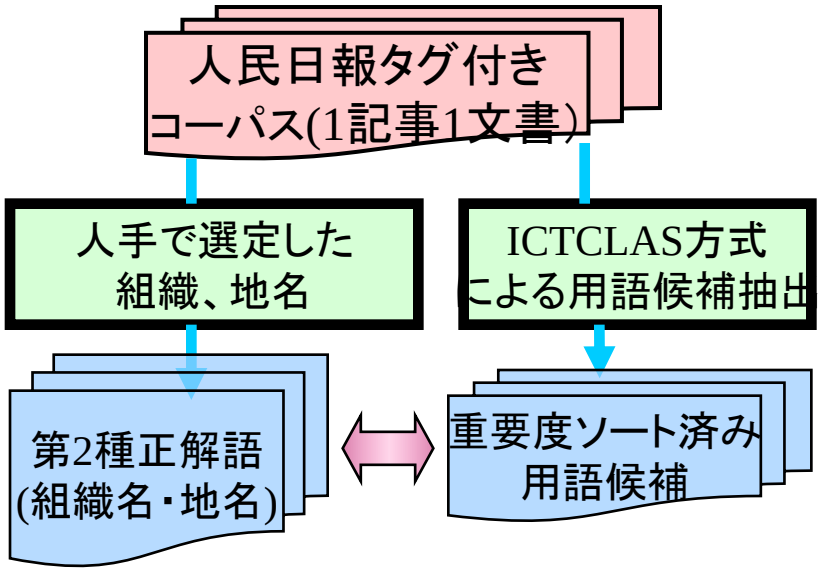
↓

その違いの原因について調査を行う

第2種正解語・1記事1文書（組織名、地名のみ）

ICTCLAS方式による用語候補





重要度計算方式	平均適合率(%)
単語FLR	13.42
単語LR	11.62
文字FLR	13.33
文字LR	12.38
Frequency	11.79
TF	12.25

組織名と地名の影響（考察）

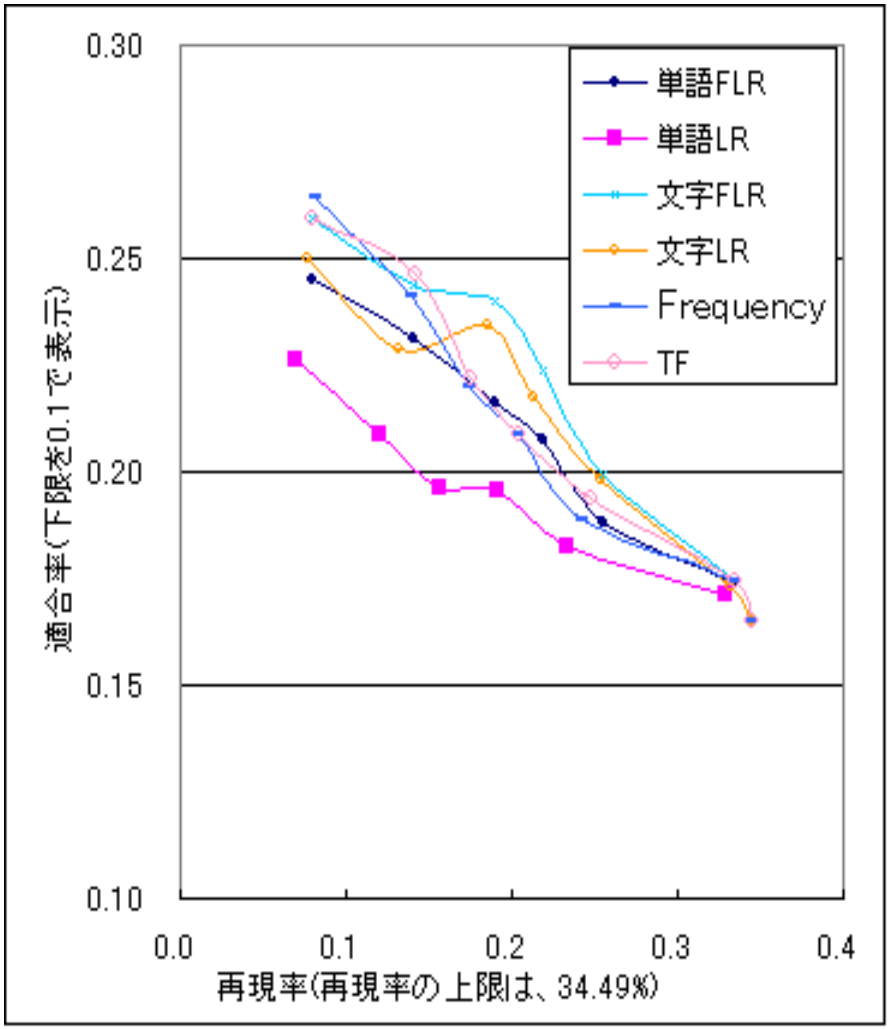
単語FLRは、第1種正解語の
96%を占める「組織名」「地名」に
限定しても同様に優良

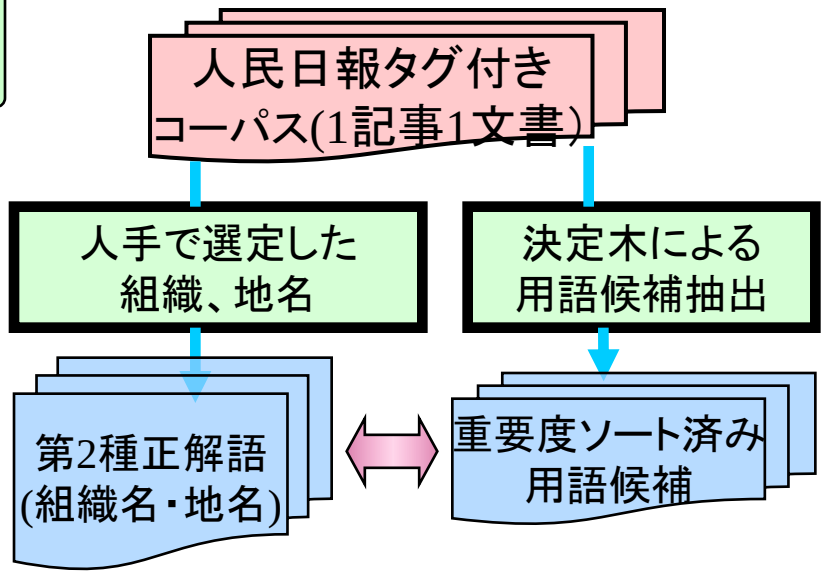
これは第1種正解語・決定木による用語候補で
文字FLRが優良となる結果と異なる

「組織名」「地名」で文字FLRが優良となったのではない
そこで今度は用語抽出方法の影響を調べてみる

第2種正解語・1記事1文書（組織名、地名のみ）

決定木による用語候補

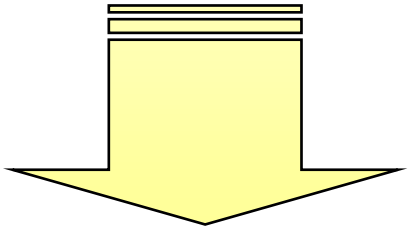




重要度計算方式	平均適合率(%)
単語FLR	19.34
単語LR	18.43
文字FLR	20.06
文字LR	19.27
Frequency	19.75
TF	19.79

文字LRの意味

用語が十分に長ければ、文字の連接は文字の出現頻度に近似できる。文字LRは単語LRより用語を小さく分割するため、その傾向が強い。



文字LRは文字の連接ではなく、頻出する漢字を含む用語を上位にしたという意味にも考えられる。

組織名と地名に限定での用語抽出方式の比較

同じ正解リストに対して

ICTCLAS方式 → 単語FLRが優良

決定木による学習 → 文字FLRと用語出現頻度が優良

決定木による用語候補抽出は「正解語」としての確率が高い用語候補を抽出する。
それと頻度的な方式の相性が良いのでは

おわりに

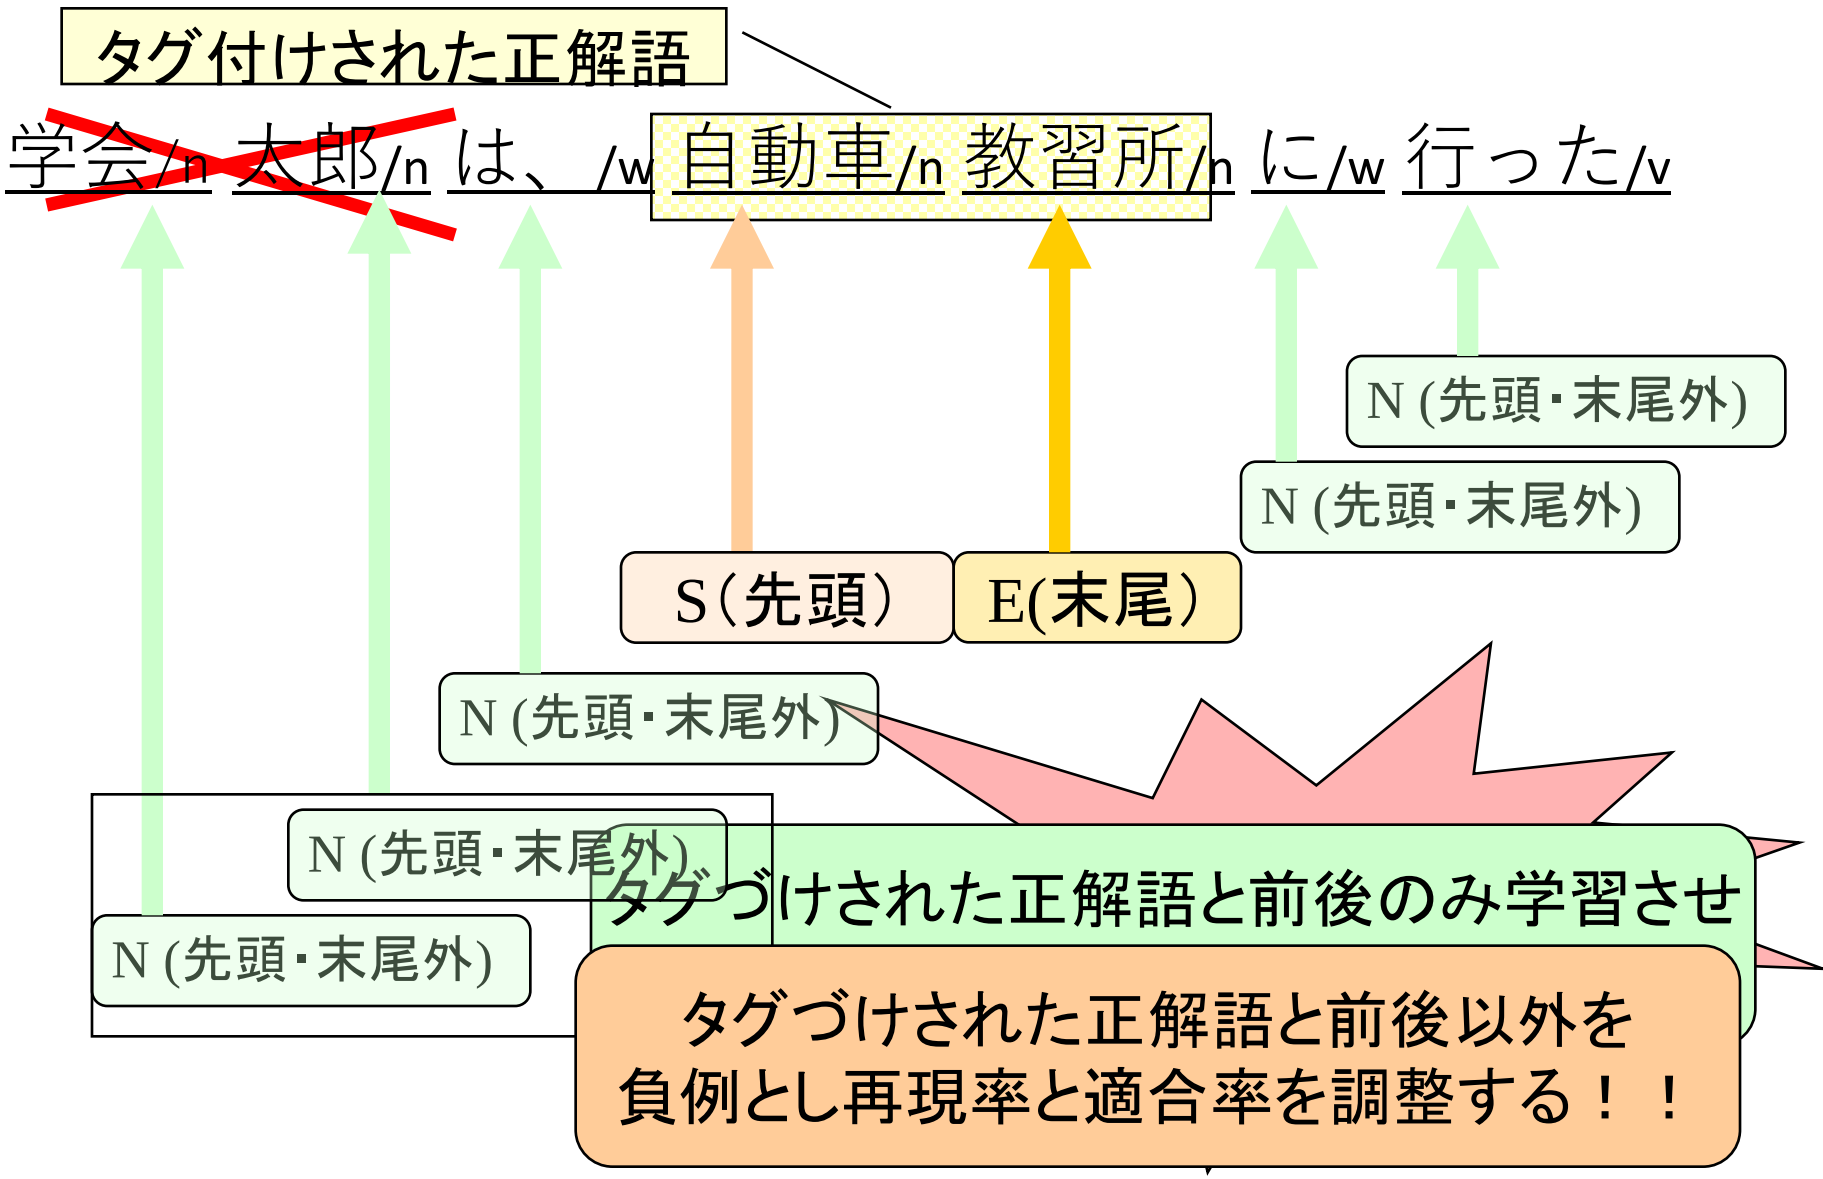
- 文字FLRと単語FLRは、有効に働くケースが異なる
- 別のジャンルのテキストによる評価が今後の重要な課題

ご清聴ありがとうございました

- 参考文献

  - Hiroshi Nakagawa, Hiroyuki Kojima, Akira Maeda, "Chinese Term Extractionfrom Web Pages Based on Compound word Productivity", 42nd Annual Meeting of the Association for Computational Linguistics (ACL2004), ThirdSIGHAN Workshop on Chinese Language Processing, pp.79-85, Barcelona,　Spain, July, (2004).
  - Nakagawa, H. and Tatsunori Mori. “Automatic term recognition based on statistics of compound words and their Components.” Terminology, 9(2), pp.201-219 (2003)
  - S.Sekine, R.Grishman and H.Shinnou, “A Decision Tree Method for Finding and Classifying Names in Japanese Texts”, 6th Workshop on Very Large Corpora , pp.148-152 (1998).
  - 永田昌明:「確率モデルによる自然言語解析」, 言語と心理の統計, 岩波書店, 2003
  - 山崎直樹「キーワード自動抽出システム『言選web』（中国語バージョン）を検証する」, 漢字文献情報処理研究6, 好文出版社, 2005.10 発行予定

第1種正解語抽出手法(正例と負例)



ストップワードリスト(一部抜粋)

自己 总共 总算 纵然 昨天 左面 阿嚏 嘣嘣 潺潺
哧溜 脆生 滴答 丁当 嘎巴 咯吱 咕咚 咕嘟 咕噜
呱呱 哈哈 哼哈 呼噜 哗啦 叽叽 嘎嘎 喳喳 本月
乒乓 扑通 比较 毕竟 必定 必然 嘻嘻 点儿 要是
一边 一面 也要 也不 别看 别说 何必 哎呀 我国
起来 来着 所谓 会得 方今 方得
啊 按 吧 把 被 比 彼 必 边 便 别 并 不 才
除 次 从 打 但 当 倒 到 得 等 点 顶 都 对
吨 多 俄 而 耳 尔 凡 个 跟 更 故 顾 过 何
很 哼 后 乎 还 或 极 及 即 几 既 间 将 叫
今 竟 净 久 就 咯 可 况 啦 …